

PRUEBA TÉCNICA DE CONOCIMIENTO

Perfil: Ingeniero de Datos

End-to-End Data Pipeline Challenge

Duración estimada	7 días hábiles
Modalidad	Individual — Repositorio Git + presentación
Plataformas validas	Microsoft Azure, Amazon AWS, Google Cloud Platform, Microsoft Fabric
Herramientas IaC	Terraform, Bicep, AWS CloudFormation, Google Deployment Manager, UI (ver rubrica)
Entrega	Repositorio Git compartido + evidencias de ejecución + README completo

INTRODUCCIÓN

Esta prueba técnica está diseñada para evaluar las competencias end-to-end de un Ingeniero de Datos moderno. El candidato deberá demostrar habilidades en diseño de arquitecturas de datos, generación de datos sintéticos, infraestructura como código, construcción de pipelines de ingesta y transformación, orquestación de flujos de trabajo y gobierno de datos.

La prueba simula un escenario real de negocio. El candidato tomara decisiones técnicas justificadas en cada etapa, desde la infraestructura hasta la capa de consumo analítico. No existe una única solución correcta; se valora la coherencia técnica, la documentación de supuestos y la calidad del razonamiento.

¿Qué se evalúa?

- Capacidad de leer un requisito de negocio y diseñar un modelo de datos acorde
- Decisiones de arquitectura en la nube: plataforma, servicios y patrones de diseño
- Dominio de herramientas de Infraestructura como Código (IaC)
- Construcción de pipelines con arquitectura Medallón: Bronze, Silver y Gold
- Orquestación de flujos de trabajo y manejo de dependencias entre tareas
- Aplicación de seguridad, roles, permisos y notificaciones operacionales
- Calidad del Código, documentación técnica y claridad en la presentación de la solución

Reglas generales

El candidato tiene libertad de elección en plataforma cloud, herramientas de IaC y motor de procesamiento. Cada decisión debe quedar documentada y justificada en el README del repositorio. La plataforma elegida debe ser consistente a lo largo de toda la solución.

De los diferentes escenarios de negocio debe escoger **ÚNICAMENTE 1** de ellos, con el que tenga mayor afinidad y hacer todo su desarrollo completo.

El tiempo máximo de entrega es de **siete (7) días hábiles** contados desde la recepción de este documento. Ante cualquier duda de interpretación, el candidato debe documentar el supuesto adoptado y continuar con el desarrollo.

ESCENARIOS DE NEGOCIO — SELECCION DEL SECTOR

A continuación, se presentan cuatro escenarios de negocio de sectores diferentes. El candidato debe leer los cuatro, seleccionar solo uno y desarrollar la prueba completa sobre ese escenario. La elección debe quedar documentada en el README del repositorio y ser la primera declaración del documento.

Independientemente del sector elegido, la arquitectura técnica requerida es idéntica para todos: laC, generación de datos, proceso Medallion y gobierno de datos. Lo que varía entre sectores es el modelo de datos y las reglas de negocio específicas.

ESCENARIO A — BANCA Y SERVICIOS FINANCIEROS

Contexto del negocio

FinBank S.A. es un banco digital fundado en 2015 con presencia en cinco países de Latinoamérica: Colombia, Mexico, Peru, Chile y Argentina. Opera exclusivamente a través de canales digitales — aplicación móvil, portal web y una red de corresponsales bancarios — y cuenta con más de dos millones de clientes activos. Su cartera de crédito supera los USD 800 millones y el banco procesa en promedio 1.2 millones de transacciones diarias entre pagos, transferencias, recargas y avances.

El modelo de negocio se basa en tres líneas de producto: crédito de consumo (créditos de libre inversión, crédito rotativo y tarjeta digital), cuentas de ahorro digitales y servicios transaccionales como pagos PSE, transferencias ACH y corresponsalía. La base de clientes esta segmentada internamente en cuatro categorías: básico para ingresos inferiores a dos salarios mínimos, estándar entre dos y cinco, Premium entre cinco y quince, y Elite para clientes de alto patrimonio.

El equipo de Riesgo Crediticio, compuesto por doce analistas y tres científicos de datos, monitorea diariamente el comportamiento de la cartera y calcula las provisiones regulatorias exigidas por la Superintendencia Financiera. Hoy trabaja con reportes manuales en Excel contruidos cada mañana durante dos horas a partir de múltiples bases desconectadas, lo que genera inconsistencias, retrasos y riesgo operativo. El área de prevención de Fraude opera en paralelo con reglas manuales que requieren ser enriquecidas con señales históricas del comportamiento del cliente. La necesidad central es un pipeline que consolide toda esta información para que ambos equipos consuman datos confiables y actualizados sin procesos manuales.

Necesidades del negocio

- Construir un indicador diario de mora por cliente, producto y región para que el equipo de riesgo identifique en que segmento y geografía se deteriora la cartera antes de que los créditos entren en etapas avanzadas de impago
- Detectar automáticamente transacciones con comportamiento atípico respecto al histórico del cliente, considerando monto, frecuencia diaria, canal utilizado y horario, para alimentar las reglas del motor de fraude.
- Calcular mensualmente el Customer Lifetime Value de cada cliente integrando ingresos por intereses, comisiones cobradas y costo de incentivos otorgados.
- Generar los insumos para los reportes regulatorios: número de cuentas activas por producto, total de transacciones, volúmenes por canal y por ciudad.
- Proveer al equipo comercial una vista consolidada del cliente con nivel de uso de productos, historial de pagos y segmento de riesgo para apoyar decisiones de oferta.

Fuente de datos (tablas de origen)

Estas son estructuras de las tablas que existen en el sistema transaccional de FinBank. Los nombres reflejan la nomenclatura interna del sistema legado. El candidato debe generar datos sintéticos con estas estructuras y estos nombres exactos.

Tabla en la fuente	Campos principales	Volumen minimo
TB_CLIENTES_CORE	id_cli, nomb_cli, apell_cli, tip_doc, num_doc, fec_nac, fec_alta, cod_segmento, score_buro, ciudad_res, depto_res, estado_cli, canal_adquis	10.000 registros
TB_PRODUCTOS_CAT	cod_prod, desc_prod, tip_prod, tasa_ea, plazo_max_meses, cuota_min, comision_admin, estado_prod	50 registros
TB_MOV_FINANCIEROS	id_mov, id_cli, cod_prod, num_cuenta, fec_mov, hra_mov, vr_mov, tip_mov, cod_canal, cod_ciudad, cod_estado_mov, id_dispositivo	500.000 registros

TB_OBLIGACIONES	id_oblig, id_cli, cod_prod, vr_aprobado, vr_desembolsado, sdo_capital, vr_cuota, fec_desembolso, fec_venc, dias_mora_act, num_cuotas_pend, calif_riesgo	30.000 registros
TB_SUCURSALES_RED	cod_suc, nom_suc, tip_punto, ciudad, depto, latitud, longitud, activo	200 registros
TB_COMISIONES_LOG	id_comision, id_cli, cod_prod, fec_cobro, vr_comision, tip_comision, estado_cobro	80.000 registros

Procesamiento zona de bronze y silver: limpieza y preprocesamiento

En la zona silver se debe garantizar una correcta estructuración, limpieza, mapeo y enriquecimiento del dato que se ingirió en la fase anterior (TB_CLIENTES_CORE, TB_PRODUCTOS_CAT, TB_MOV_FINANCIEROS, TB_OBLIGACIONES, TB_SUCURSALES_RED, TB_COMISIONES_LOG) usando los formatos adecuados para procesamiento de big data, además se debe garantizar seguridad de la información utilizando mecanismo de encriptación y/o enmascaramiento de la data sensible como numero de documentos, valores de estado de cuenta, etc.

Procesamiento zona Gold: creación de dim y fact con lógicas de negocio

La capa Gold debe contener un modelo dimensional limpio. Las siguientes tablas destino son dimensiones (dim) o tablas de hechos (fact) que el candidato construye a partir de las fuentes anteriores de acuerdo con las lógicas de negocio requeridas.

Tabla fuente (origen)	Tabla destino en Gold	Transformaciones clave en Silver y Gold
TB_CLIENTES_CORE	dim_clientes	Unificar nombre completo desde nomb_cli + apell_cli, calcular edad desde fec_nac, mapear cod_segmento a etiqueta legible.
TB_PRODUCTOS_CAT	dim_productos	Renombrar campos a nombres de negocio, calcular tasa mensual equivalente desde tasa_ea, clasificar en familia: crédito, ahorro o transaccional
TB_SUCURSALES_RED	dim_geografia y dim_canal	Separar en dos dimensiones: dim_geografia con ciudad y depto,

		dim_canal con tipo de punto de atención y canal digital
TB_MOV_FINANCIEROS	fact_transacciones	Validar id_cli contra dim_clientes, calcular monto en USD desde COP, agregar flag de horario (habil / no habil), calcular promedio movil de 30 dias por cliente para deteccion de anomalias
TB_OBLIGACIONES	fact_cartera	Calcular bucket_mora a partir de dias_mora_act en cinco rangos, derivar clasificacion regulatoria A/B/C/D/E, calcular provision estimada segun tabla regulatoria
TB_COMISIONES_LOG + TB_MOV_FINANCIEROS	fact_rentabilidad_cliente	Join por id_cli y periodo mensual; calcular ingreso total = intereses + comisiones; calcular CLTV como suma historica de 12 meses

Reglas de negocio:

- Clasificar el campo dias_mora_act de TB_OBLIGACIONES en cinco rangos en fact_cartera: Al día (0), Rango 1 (1-30 dias), Rango 2 (31-60), Rango 3 (61-90) y Deteriorado (más de 90). El campo calculado se llama bucket_mora.
- Marcar una transacción de TB_MOV_FINANCIEROS como sospechosa cuando su vr_mov supere en más de tres desviaciones estándar el promedio de los últimos 30 días del mismo cliente. El flag ind_sospechoso debe calcularse en Silver antes de llegar a Gold.
- El CLTV mensual en fact_rentabilidad_cliente se calcula como la suma de todos los ingresos por intereses más comisiones efectivamente cobradas en los últimos doce meses calendario por cliente.
- La tabla de KPIs diarios de cartera debe agregar por fecha, producto, segmento y ciudad: total de obligaciones activas, monto total de cartera, monto en mora, tasa de mora como porcentaje y clientes con alguna obligación en mora

ESCENARIO B — RETAIL Y COMERCIO ELECTRONICO

Contexto del negocio

RetailMax es una cadena de retail de consumo masivo fundada en 1998 con presencia física en Colombia, Mexico, Chile, Peru y Ecuador. Opera 148 tiendas distribuidas entre hipermercados, supermercados de barrio y tiendas de conveniencia, y desde 2019 cuenta con un canal de e-commerce propio y presencia en los principales marketplaces de la región. Sus ventas anuales consolidadas superan los USD 1.200 millones con un crecimiento del canal digital del 34% en el último año fiscal.

El catálogo activo contiene aproximadamente 48.000 referencias de producto agrupadas en seis macro categorías: Alimentos y bebidas, Cuidado personal e higiene, Hogar y limpieza, electrónica y tecnología, Ropa y calzado básico, y Bebés y maternidad. El reabastecimiento opera desde tres centros de distribución regionales en Bogotá, Ciudad de Mexico y Santiago de Chile, con frecuencia de despacho a tienda de uno a tres días según la velocidad de rotación de cada categoría.

El área de Supply Chain estima que un quiebre de stock en una referencia de alta rotación genera una pérdida de entre el 3% y el 8% de las ventas proyectadas, con riesgo adicional de migración del cliente al competidor. Hoy el equipo revisa inventarios tres veces por semana de forma manual, dejando ventanas de hasta 48 horas sin visibilidad. El área de Marketing necesita segmentar los 7.2 millones de miembros del programa de

fidelización usando RFM, ya que la segmentación actual por frecuencia produce campañas con tasas de apertura inferiores al 12%. El área de Devoluciones gestiona 18.000 devoluciones mensuales sin visibilidad sistemática sobre causas ni proveedores problemáticos.

Necesidades del negocio

- Identificar diariamente referencias con riesgo de quiebre en los próximos siete días considerando stock actual, velocidad de consumo de los últimos catorce días y tiempo de reabastecimiento desde el centro de distribución.
- Calcular el score RFM de cada cliente del programa de fidelización con actualización semanal para segmentar en al menos cinco grupos de valor.
- Calcular la tasa de conversión por canal y por categoría: cuantos clientes que visitaron el sitio o tienda efectivamente compraron y cuál es el ticket promedio por canal.
- Analizar devoluciones por motivo, categoría, proveedor y canal para identificar patrones que permitan reducir la tasa mediante acciones preventivas.
- Construir una vista de ventas diarias consolidada por país, tienda, canal y categoría para el dashboard ejecutivo de la dirección comercial.

Fuente de datos (tablas de origen)

Estas son estructuras de las tablas que existen en el sistema transaccional de FinBank. Los nombres reflejan la nomenclatura interna del sistema legado. El candidato debe generar datos sintéticos con estas estructuras y estos nombres exactos.

Tabla en la fuente	Campos principales	Volumen minimo
MSTR_ARTICULOS	art_id, cod_barra, desc_art, id_categ_n1, id_categ_n2, id_categ_n3, id_proveedor, precio_lista, peso_kg, unid_medida, activo, fec_alta	5.000 registros
MSTR_PROVEEDORES	id_proveedor, razon_social, pais_origen, tiempo_repo_dias, calificacion_calidad, activo	800 registros
MSTR_TIENDAS	id_tienda, nom_tienda, tipo_tienda, id_ciudad, id_pais, metros_cuadrados, activo, fec_apertura	150 registros
CRM_MIEMBROS	id_miembro, fec_registro, id_ciudad, genero, rango_edad, canal_pref, activo, fec_ultima_compra	50.000 registros
TRANS_VENTAS	id_trans, id_miembro, id_tienda, art_id, fec_trans, hra_trans, qty_vendida, precio_unitario_venta, descuento_aplicado, tipo_pago, canal_venta	1.000.000 registros
INV_STOCK_DIARIO	id_snapshot, art_id, id_tienda, fec_snapshot, stock_fisico, stock_transito, stock_reservado, stock_minimo_config, stock_maximo_config	750.000 registros
POST_DEVOLUCIONES	id_devolucion, id_trans_origen, art_id, id_tienda, fec_devolucion, qty_devuelta, motivo_cod, canal_devolucion, estado_devolucion, vr_reembolso	50.000 registros

Procesamiento zona de bronze y silver: limpieza y preprocesamiento

En la zona silver se debe garantizar una correcta estructuración, limpieza, mapeo y enriquecimiento del dato que se ingestó en la fase anterior (MSTR_ARTICULOS, TRANS_VENTAS, MSTR_PROVEEDORES, INV_STOCK_DIARIO, POST_DEVOLUCIONES, MSTR_TIENDAS, CRM_MIEMBROS) usando los formatos adecuados para procesamiento de big data, además se debe garantizar seguridad de la información utilizando mecanismo de encriptación y/o enmascaramiento de la data sensible como numero de documentos, valores de estado de cuenta, etc.

Procesamiento zona Gold: creación de dim y fact con lógicas de negocio

La capa Gold debe contener un modelo dimensional limpio. Las siguientes tablas destino son dimensiones (dim) o tablas de hechos (fact) que el candidato construye a partir de las fuentes anteriores de acuerdo con las lógicas de negocio requeridas.

Tabla fuente (origen)	Tabla destino en Gold	Transformaciones clave en Silver y Gold
MSTR_ARTICULOS + MSTR_PROVEEDORES	dim_productos	Join por id_proveedor; construir jerarquía de categorías (nivel 1, 2 y 3) como campos planos; calcular margen estimado por categoría
MSTR_TIENDAS	dim_tiendas	Estandarizar tipo_tienda a catalogo controlado; enriquecer con ciudad y país; calcular zona de distribución asignada
CRM_MIEMBROS	dim_clientes	Calcular antigüedad en días desde fec_registro; imputar rango_edad nulo con la mediana del canal preferido; estandarizar genero a M, F o No informado
TRANS_VENTAS	fact_ventas	Calcular vr_venta_neto = qty_vendida x precio_unitario - descuento; validar id_miembro contra dim_clientes o asignar cliente anonimo; agregar indicador de venta con descuento
INV_STOCK_DIARIO	fact_inventario	Calcular cobertura_dias = stock_fisico / promedio_consumo_14dias; flag alerta_quiebre cuando cobertura_dias sea menor a 7; calcular diferencia frente a stock_minimo_config
POST_DEVOLUCIONES + TRANS_VENTAS	fact_devoluciones	Join con la venta origen para obtener precio original; estandarizar motivo_cod a descripción legible; calcular tasa_devolucion por artículo y categoría
TRANS_VENTAS + CRM_MIEMBROS (agregado)	fact_rfm_clientes	Calcular R como días desde última transacción, F como número de transacciones en 90 días, M como valor monetario en 90 días; asignar score 1 a 5 por quintiles y construir segmento RFM

Reglas de negocio para la capa Gold

- El score RFM se calcula sobre los últimos 90 días. Cada dimensión recibe un puntaje de 1 a 5 usando quintiles sobre todos los clientes activos (al menos una compra en 180 días). El segmento final se construye concatenando los tres scores, por ejemplo, R5-F4-M5 = Champions.

- Una referencia entra en alerta de quiebre cuando cobertura días sea menor a 7 Y el promedio de ventas de los últimos 14 días sea mayor a cero. Referencias sin ventas en 14 días no generan alerta.
- La tasa de devolución por categoría se calcula como unidades devueltas sobre unidades vendidas en el mismo periodo, expresada en porcentaje, por categoría de nivel 1 y por canal de venta.
- El dashboard ejecutivo consolida diariamente: ventas netas por país y canal, comparativo versus el mismo día de la semana anterior, top 10 de artículos por categoría y tasa de descuento promedio aplicada

ESCENARIO C — SALUD Y SERVICIOS MEDICOS

Contexto del negocio

HealthNet es una red de salud privada fundada en 1987 con operaciones en Colombia, Peru y Ecuador. Administra 82 sedes: tres hospitales de alta complejidad, dieciséis clínicas de mediana complejidad, cuarenta y dos centros médicos ambulatorios y veintiún centros de diagnóstico especializado. Emplea a más de 9.400 personas y atiende aproximadamente 2.8 millones de consultas anuales con convenios activos con cuarenta y dos aseguradoras y EPS.

La operación se financia en un 68% mediante facturación a aseguradoras por servicios cubiertos, lo que exige una codificación diagnostica precisa según CIE-10 para que las facturas no sean objetadas. El 32% restante proviene de pagos directos de pacientes particulares y contratos de capacitación con entidades territoriales.

El área de Operaciones Medicas enfrenta tres problemas estructurales. Primero, la ocupación de camas en hospitales de alta complejidad supera el 90% en temporadas de alta demanda, generando saturación y redirección de pacientes con costos logísticos y clínicos significativos. Segundo, los tiempos de espera en consulta externa superan los 45 minutos en promedio con picos de hasta 3 horas en algunas especialidades. Tercero, no existe visibilidad centralizada sobre comportamiento epidemiológico: los brotes se detectan semanas después de ocurrir. El pipeline debe integrar los sistemas de historia clínica electrónica, gestión de camas, agendamiento y facturación, actualmente desconectados entre sí.

Necesidades del negocio

- Monitorear diariamente la tasa de ocupación de camas por especialidad, tipo de unidad (general, UCI, cirugía, urgencias) y sede, con identificación automática de sedes en estado crítico.
- Calcular el tiempo promedio de espera desde el registro del paciente hasta el inicio de atención, segmentado por especialidad, tipo de consulta (primera vez o control) y sede.
- Detectar aumentos atípicos en la frecuencia de diagnósticos CIE-10 por región y grupo de edad comparando el volumen actual con el promedio de las últimas ocho semanas.
- Calcular el costo promedio de atención por diagnóstico principal y tipo de consulta para apoyar negociaciones de tarifas con aseguradoras.
- Construir el perfil de uso de servicios por paciente: número de consultas, especialidades, frecuencia anual y costo histórico acumulado para segmentar según complejidad de atención.

Fuente de datos (tablas de origen)

Tabla en la fuente	Campos principales	Volumen mínimo
PAC_REGISTRO	pac_id, tip_doc, num_doc_hash, fec_nac, genero, id_ciudad_res, tip_aseguradora, id_eps, estrato_socioec, fec_primer_atencion, activo	100.000 registros
MED_PLANTA	med_id, esp_principal, esp_secundaria, id_sede, fec_ingreso, tip_contrato, jornada, estado_activo	2.000 registros
RED_SEDES	id_sede, nom_sede, tip_sede, id_ciudad, id_pais, cap_camias_gen, cap_camias_uci, cap_camias_cirugia, cap_camias_urg, nivel_complejidad	82 registros
HCE_ENCUNTROS	id_encuentro, pac_id, med_id, id_sede, fec_registro, fec_inicio_atencion, fec_egreso, tip_consulta, esp_atendida, diag_principal_cie10, diag_sec1_cie10, cod_procedimientos, vr_facturado, estado_factura	2.000.000 registros
GCM_CAMAS	id_registro_cama, id_sede, tip_unidad, fec_hora_registro, num_camias_ocupadas,	500.000 registros

	num_camas_disp, num_camas_mant, motivo_indisponibilidad	
FAR_DISPENSACION	id_dispensacion, id_encuentro, pac_id, id_sede, fec_dispensacion, cod_medicamento, nom_medicamento, cantidad, vr_unitario, tip_prescripcion	3.000.000 registros
AGE_CITAS	id_cita, pac_id, med_id, id_sede, fec_agendamiento, fec_cita_programada, hra_cita_programada, hra_llegada_paciente, hra_inicio_atencion, esp_solicitada, tip_cita, estado_cita	1.500.000 registros

Procesamiento zona de bronze y silver: limpieza y preprocesamiento

En la zona silver se debe garantizar una correcta estructuración, limpieza, mapeo y enriquecimiento del dato que se ingestó en la fase anterior (PAC_REGISTRO, AGE_CITAS, FAR_DISPENSACION,

GCM_CAMAS, POST_DEVOLUCIONES, RED_SEDES, HCE_ENCUENTROS, MED_PLANTA) usando los formatos adecuados para procesamiento de big data, además se debe garantizar seguridad de la información utilizando mecanismo de encriptación y/o enmascaramiento de la data sensible como numero de documentos, valores de estado de cuenta, etc.

Procesamiento zona Gold: creación de dim y fact con lógicas de negocio

La capa Gold debe contener un modelo dimensional limpio. Las siguientes tablas destino son dimensiones (dim) o tablas de hechos (fact) que el candidato construye a partir de las fuentes anteriores de acuerdo con las lógicas de negocio requeridas.

Tabla fuente (origen)	Tabla destino en Gold	Transformaciones clave en Silver y Gold
PAC_REGISTRO	dim_pacientes	Calcular grupo de edad en rangos (0-12, 13-17, 18-40, 41-65, +65); num_doc_hash ya viene enmascarado desde la fuente; estandarizar tip_aseguradora a catalogo controlado

MED_PLANTA + RED_SEDES	dim_medicos	Join por id_sede para enriquecer con nombre y tipo de sede; calcular anos_experiencia desde fec_ingreso
RED_SEDES	dim_sedes	Calcular capacidad_total_camras = suma de los cuatro tipos; calcular porcentaje de UCI sobre capacidad total
HCE_ENCUEENTROS	fact_consultas	Calcular tiempo_estadia_horras como diferencia entre fec_egreso y fec_registro; estandarizar diag_principal_cie10 a tres caracteres para agrupacion por capitulo; flag glosa_riesgo cuando el codigo no coincide con la especialidad del medico
GCM_CAMAS	fact_ocupacion_camras	Calcular tasa_ocupacion = num_camras_ocupadas / (num_camras_ocupadas + num_camras_disp); clasificar sede en Critico, Precaucion o Normal; agregar por sede, tipo de unidad y fecha
AGE_CITAS	fact_tiempos_espera	Calcular tiempo_espera_min = diferencia entre hra_llegada_paciente y hra_inicio_atencion; filtrar solo citas con estado_cita = Atendida; enviar registros con tiempo negativo a tabla de errores
FAR_DISPENSACION + HCE_ENCUEENTROS	fact_costos_atencion	Join por id_encuentro; calcular costo_total = vr_facturado + suma de vr_unitario x cantidad de medicamentos; agregar por diagnostico principal y tipo de consulta

Reglas de negocio para la capa Gold

- La clasificación de estado en fact_ocupacion_camras se aplica por tipo de unidad de forma independiente: UCI Critico cuando supere el 85%, Urgencias Critico cuando supere el 90%, camras generales Critico cuando superen el 88%. Los umbrales deben estar parametrizados en un archivo de configuración para poderse ajustar sin modificar el código.
- Una alerta de brote epidemiológico se genera cuando el volumen de consultas con el mismo Código CIE-10 (tres caracteres) en una ciudad supera en más del 40% el promedio de las ultimas ocho semanas. El resultado se almacena en fact_alertas_epidemiologicas con: fecha, codigo CIE-10, ciudad, volumen actual, promedio historico y porcentaje de desviación.

- El tiempo de espera en `fact_tiempos_espera` excluye registros donde `hra_llegada_paciente` sea nula o el tiempo calculado sea negativo. Esos registros van a la tabla de errores del pipeline.
- El perfil de complejidad del paciente se construye en `dim_complejidad_paciente` en cuatro niveles: Bajo (menos de 2 consultas al año y sin diagnósticos crónicos), Moderado (2 a 5 consultas o un diagnóstico crónico), Alto (más de 5 consultas o dos o más diagnósticos crónicos), y Muy Alto (hospitalizaciones o diagnósticos oncológicos en el año).

ESCENARIO D — LOGISTICA Y CADENA DE SUMINISTRO

Contexto del negocio

LogiTrack S.A.S. es una empresa de logística especializada en distribución de última milla fundada en 2016 en Medellín. En ocho años ha expandido su cobertura a diez ciudades colombianas: Bogotá, Cali, Barranquilla, Medellín, Bucaramanga, Pereira, Manizales, Cartagena, Santa Marta y Cucuta. Opera una flota mixta de 1.200 vehículos entre motos, bicicletas de carga, vanes y camiones, y procesa en promedio 35.000 envíos diarios en temporada regular con picos de hasta 90.000 en noviembre y diciembre.

Sus clientes son principalmente empresas de e-commerce, retailers con canal digital, laboratorios farmacéuticos y empresas de telecomunicaciones. El SLA estándar establece entrega en el mismo día para pedidos recibidos antes de las 10:00 a.m. y entrega al día siguiente hábil para pedidos posteriores, con penalizaciones contractuales por incumplimiento de entre el 2% y el 8% del valor del envío fallido.

El problema central es una tasa de entrega fallida del 14.3%, muy por encima del benchmarking del sector del 8%. Las causas declaradas por conductores son: destinatario ausente (41%), dirección incorrecta (27%), zona de difícil acceso (18%), paquete rechazado (9%) y otros (5%). Sin embargo, el equipo sospecha que la categoría destinatario ausente encubre casos de mala planificación de rutas, ventanas de entrega no comunicadas y falta de contacto previo. Adicionalmente, el sistema de bonos se basa únicamente en el número bruto de entregas, generando incentivos perversos donde algunos conductores registran intentos fallidos sin haberlos realizado.

Necesidades del negocio

- Calcular la tasa de entrega exitosa a nivel de conductor, zona, tipo de paquete y cliente remitente con actualización diaria para cuantificar el costo por penalizaciones del SLA.
- Construir un score de desempeño multidimensional por conductor que integre al menos cinco variables para que los bonos de productividad sean calculados de forma justa y basada en datos.
- Analizar los patrones de fallo por zona cruzando la causa declarada con el horario de intento y el histórico de la zona, para distinguir entre fallos estructurales de la zona y fallos atribuibles al conductor.
- Identificar zonas con mayor concentración de retrasos respecto al tiempo comprometido considerando tráfico histórico por hora y día de la semana.
- Generar una vista de trazabilidad completa de cada envío desde la recepción del pedido hasta la entrega o devolución al remitente, consultable por el área de servicio al cliente

Fuente de datos (tablas de origen)

Tabla en la fuente	Campos principales	Volumen minimo
OPE_CONDUCTORES	cond_id, nomb_cond, apell_cond, tip_doc, num_doc_hash, fec_ingreso, id_ciudad_base, tip_vehiculo, cod_zona_asignada, activo, calific_promedio_acum	500 registros
CLI_REMITENTES	id_remitente, razon_social, tipo_cliente, ciudad_principal, sla_entrega_horas, penalidad_porc, activo	200 registros
GEO_ZONAS	id_zona, nom_zona, id_ciudad, barrio_referencia, latitud_centroide, longitud_centroide, nivel_trafico_prom, tip_zona, distancia_bodega_km	300 registros
TMS_ENVIOS	id_envio, id_remitente, cond_id, id_zona_destino, tip_paquete, peso_kg, fec_recepcion, hra_recepcion, fec_entrega_programada, fec_intento1, hra_intento1, resultado_intento1,	2.000.000 registros

	fec_intento2, hra_intento2, resultado_intento2, fec_entrega_real, estado_final, motivo_fallo_cod, vr_declarado	
GPS_RUTAS	id_ruta, cond_id, fec_ruta, hra_inicio, hra_fin, km_recorridos, num_paradas_plan, num_paradas_real, desviacion_ruta_km, consumo_combustible	100.000 registros
CAL_DESTINATARIOS	id_calificacion, id_envio, fec_calificacion, puntaje_1_5, comentario_texto, canal_calificacion	300.000 registros
DIR_NOVEDADES	id_novedad, id_envio, fec_novedad, tip_novedad, desc_novedad, id_agente_registro, requiere_accion	150.000 registros

Procesamiento zona de bronze y silver: limpieza y preprocesamiento

En la zona silver se debe garantizar una correcta estructuración, limpieza, mapeo y enriquecimiento del dato que se ingestó en la fase anterior (OPE_CONDUCTORES, DIR_NOVEDADES, CAL_DESTINATARIOS, CLI_REMITENTES, GPS_RUTAS, TMS_ENVIOS, GEO_ZONAS) usando los formatos adecuados para procesamiento de big data, además se debe garantizar seguridad de la información utilizando mecanismo de encriptación y/o enmascaramiento de la data sensible como numero de documentos, valores de estado de cuenta, etc.

Procesamiento zona Gold: creación de dim y fact con lógicas de negocio

La capa Gold debe contener un modelo dimensional limpio. Las siguientes tablas destino son dimensiones (dim) o tablas de hechos (fact) que el candidato construye a partir de las fuentes anteriores de acuerdo con las lógicas de negocio requeridas.

Tabla fuente (origen)	Tabla destino en Gold	Transformaciones clave en Silver y Gold
OPE_CONDUCTORES	dim_conductores	Calcular antigüedad en años desde fec_ingreso; estandarizar tip_vehiculo a catalogo controlado (Moto, Bicicleta, Van, Camion); num_doc_hash ya viene enmascarado
CLI_REMITENTES	dim_remitentes	Estandarizar tipo_cliente a segmento de industria:

		Ecommerce, Farmaceutico, Retail, Telecomunicaciones u Otro; calcular SLA como campo numerico limpio en horas
GEO_ZONAS	dim_zonas	Calcular indice de dificultad operativa combinando nivel_trafico_prom y distancia_bodega_km en escala 1 a 5; enriquecer con nombre del municipio
TMS_ENVIOS	fact_envios	Calcular tiempo_entrega_real_horas = fec_entrega_real - fec_recepcion; flag cumplimiento_sla comparando contra sla_entrega_horas del remitente; estandarizar motivo_fallo_cod a descripcion legible; calcular numero de intentos realizados
GPS_RUTAS	fact_rutas	Calcular eficiencia_ruta = num_paradas_real / num_paradas_plan; calcular velocidad_promedio_kmh = km_recorridos / horas_trabajadas; calcular desviacion_porcentaje = desviacion_ruta_km / km_recorridos x 100
TMS_ENVIOS + GPS_RUTAS + CAL_DESTINATARIOS	fact_desempeno_conductor	Join de las tres fuentes por cond_id y fecha; calcular tasa_exito por conductor; calcular score_desempeno con la formula ponderada definida en las reglas de negocio
DIR_NOVEDADES + TMS_ENVIOS	fact_trazabilidad_envio	Join por id_envio; construir linea de tiempo completa del envio como un registro por evento en orden cronologico; calcular tiempo entre cada evento y el anterior

Reglas de negocio para la capa Gold

- El score de desempeño en fact_desempeno_conductor se calcula con la siguiente formula ponderada: $(tasa_exito \times 0.35) + (adherencia_ruta_normalizada \times 0.20) + (velocidad_vs_estandar_zona \times 0.20) + (inversa_intentos_promedio \times 0.15) +$

(calificacion_destinatario_normalizada x 0.10). Cada componente debe normalizarse a escala 0-1 antes de aplicar los pesos. El score final va de 0 a 1 redondeado a dos decimales.

- La clasificación de retraso en fact_envios se calcula como la diferencia entre fec_entrega_real y fec_entrega_programada en horas. Rangos: A tiempo (0 o negativo), Retraso leve (1 a 4 horas), Retraso moderado (4 a 24 horas), Retraso critico (mas de 24 horas). Los envíos con estado final distinto de Entregado no reciben clasificación de retraso sino el estado No entregado.
- La tabla fact_alertas_zona se construye diariamente calculando por zona y día de la semana la tasa de fallo promedio de las últimas cuatro semanas. Si la tasa del día actual supera en más del 25% ese promedio, se genera un registro de alerta con: zona, fecha, tasa actual, promedio histórico y porcentaje de desviación.

ENTREGABLE FASE 1 — GENERACION DE DATOS Y MODELO RELACIONAL

Una vez seleccionado el sector, el candidato debe generar los datos sintéticos utilizando el lenguaje y la librería de su preferencia. Se recomienda Python, pyspark, aunque también son válidos R, Scala o cualquier generador SQL. El script de generación debe ser reproducible mediante una semilla aleatoria fija.

Requisitos de los datos generados

- **Distribuciones realistas:** los datos no deben ser completamente aleatorios. Por ejemplo, las ventas deben concentrarse en horarios pico, las edades deben seguir una distribución normal, y los montos de transacciones deben reflejar comportamientos típicos del sector.
- **Integridad referencial:** todos los identificadores presentes en las tablas de hechos deben existir en las tablas de dimensiones correspondientes.
- **Valores nulos controlados:** incluir aproximadamente un cinco por ciento de valores nulos en campos no críticos para simular condiciones reales de calidad de datos.
- **Cobertura temporal:** los datos deben cubrir al menos doce meses de histórico con distribución uniforme o estacional según el sector.

- **Anomalías intencionales:** incluir al menos tres patrones de datos anómalos documentados, como transacciones duplicadas, fechas fuera de rango o registros con campos inconsistentes. El pipeline deberá detectarlos o manejarlos de forma explícita.
- **Múltiples formatos de salida:** generar los datos en al menos dos formatos distintos entre CSV, JSON y Parquet para simular un escenario de ingesta heterogénea.

Carga en base de datos relacional

Los datos sintéticos deben ser cargados en una base de datos SQL que actúe como fuente origen del pipeline. El candidato puede elegir cualquiera de los siguientes motores según la plataforma seleccionada.

Plataforma	Motores recomendados	Alternativa local
Microsoft Azure	Azure SQL Database, Azure Database for PostgreSQL	SQL Server Express o PostgreSQL en Docker
Amazon AWS	Amazon RDS (PostgreSQL, MySQL o SQL Server)	PostgreSQL en Docker o SQLite para pruebas locales
Google Cloud	Cloud SQL (PostgreSQL o MySQL)	PostgreSQL en Docker
Microsoft Fabric	SQL Analytics Endpoint del Lakehouse o Warehouse	PostgreSQL local para la generación inicial

Los scripts de generación y carga de datos deben estar versionados en el repositorio Git y ser completamente reproducibles. El candidato debe incluir un archivo de configuración en formato YAML o JSON que centralice los parámetros de generación: volumen por tabla, rango de fechas y semilla aleatoria.

ENTREGABLES FASE 1

- Script de generación de datos dummy con semilla aleatoria fija y parámetros configurables
- Script SQL o Python de carga en la base de datos relacional seleccionada
- Diagrama Entidad-Relación (ER) de todas las tablas generadas, ubicado en la carpeta /docs del repositorio
- Evidencia de la carga exitosa: captura de pantalla o resultado de SELECT COUNT(*) por tabla

ENTREGABLE FASE 2 — INFRAESTRUCTURA COMO CODIGO

El candidato debe aprovisionar todos los recursos de nube necesarios para la solución utilizando una herramienta de Infraestructura como Código. La elección de la herramienta debe ser coherente con la plataforma seleccionada y debe quedar justificada en el README.

Recursos mínimos requeridos por plataforma

Plataforma	Recursos minimos a aprovisionar
Microsoft Azure	Resource Group, Storage Account con ADLS Gen2 y contenedores bronze / silver / gold, Azure Data Factory o Databricks Workspace, Azure Key Vault, Log Analytics Workspace y Action Group para alertas
Amazon AWS	S3 Buckets separados para bronze, silver y gold, AWS Glue Database con Crawlers, roles IAM con politica de minimo privilegio, CloudWatch Log Groups, SNS Topic para notificaciones y AWS Secrets Manager
Google Cloud	GCS Buckets para bronze, silver y gold, BigQuery Dataset, Cloud Composer Environment, Service Accounts con roles granulares, Cloud Logging, Pub/Sub Topic para alertas y Secret Manager

Microsoft Fabric	Workspace con capacidad trial o F2, Lakehouse con estructura bronze / silver / gold en OneLake, Data Factory de Fabric y configuración de alertas por email o Microsoft Teams
-------------------------	---

Estándares obligatorios del código IaC

- Ningún valor de credencial, contraseña o clave de acceso debe aparecer directamente en el código. Todos los secretos deben referenciarse desde el gestor de secretos de la plataforma.
- Las variables de nombre de recursos, región, entorno y tamaño de instancias deben estar parametrizadas y documentadas.
- El estado de Terraform debe almacenarse en un backend remoto: Storage Account en Azure, S3 en AWS o GCS en Google Cloud. No se debe confirmar el archivo de estado en el repositorio.
- La configuración debe soportar al menos dos entornos distintos mediante workspaces o archivos de variables separados: por ejemplo, dev y prod.
- Los outputs del módulo deben exportar los ARNs, URLs o nombres de todos los recursos creados para que puedan ser consumidos por los scripts del pipeline.

ENTREGABLES FASE 2

- Código IaC completo en la carpeta /infra del repositorio, con README de instrucciones de despliegue
- Evidencia del despliegue exitoso: captura de pantalla del portal o salida del terminal con el resultado del apply
- Lista de recursos creados con sus nombres, regiones y propósito dentro de la solución
- Archivo de variables o parámetros separado del código principal, sin credenciales expuestas

ENTREGABLE FASE 3 - PIPELINE END TO END FLUJO DE DATOS: ARQUITECTURA MEDALLION

Esta es la fase central de la prueba. El candidato debe construir un pipeline de datos que mueva la información a través de tres capas de calidad creciente aplicando transformaciones progresivas. La arquitectura debe ser idiomática: cada capa tiene un propósito claro y los datos no deben saltarse niveles.

Capa Bronze — Ingesta de datos crudos

El objetivo de esta capa es copiar los datos desde la fuente con el mínimo de transformaciones. Bronze es la única fuente de verdad del dato original y debe permitir la reproducción de cualquier estado anterior del pipeline.

- Ingestar los datos desde la base de datos SQL origen hacia el almacenamiento en la nube en formato Parquet o Delta Lake
- Mantener el esquema original de la fuente sin modificaciones
- Agregar tres columnas de metadatos de auditoría en cada registro: marca de tiempo de ingesta, sistema fuente y identificador del lote de procesamiento
- Implementar particionamiento por fecha de ingesta con la estructura año / mes / día para optimizar las consultas incrementales
- Registrar un log de cada ejecución de ingesta con el número de registros procesados, el tamaño del archivo generado y la duración total del proceso
- La ingesta debe soportar modo incremental: en ejecuciones posteriores a la inicial, el pipeline debe procesar únicamente los registros nuevos o modificados desde la última ejecución

Capa Silver — Limpieza y conformación

El objetivo de esta capa es producir datos limpios, tipados correctamente, sin duplicados y con relaciones validadas. Silver es la capa de confianza para los analíticos.

- Eliminar registros duplicados exactos y registros con campos obligatorios nulos o corrompidos.
- Estandarizar tipos de datos.
- Validar la integridad referencial entre tablas de hechos y dimensiones: los registros que referencien un identificador inexistente deben ser enviados a una tabla de errores con el motivo documentado.

- Aplicar una estrategia documentada para el manejo de valores nulos en cada columna: imputación con valor por defecto, exclusión del registro o marcado con un indicador binario.
- Aplicar enmascaramiento o hash sobre columnas que contengan información de identificación personal, como nombres, números de documento o datos de contacto.
- Generar un reporte de calidad de datos por cada ejecución: porcentaje de nulos por columna, número de registros rechazados y porcentaje de registros conformes.

Capa Gold — Modelo analítico y reglas de negocio

El objetivo de esta capa es producir tablas optimizadas para consumo analítico que implementen las reglas de negocio específicas del sector seleccionado. Gold es la capa que consumen los dashboards, los reportes y los modelos de machine learning.

- Implementar todas las reglas de negocio especificadas en la sección del sector elegido la sección de reglas de negocio de este documento.
- Construir al menos tres tablas o vistas de agregación diferentes que respondan a las necesidades del negocio descritas
- Optimizar las tablas de Gold para consultas: aplicar particionamiento por las dimensiones de análisis más frecuentes y, si la plataforma lo soporta, clustering o indexación.
- Documentar el linaje de datos de al menos tres campos calculados en la capa Gold, indicando la tabla de origen, la transformación aplicada y el propósito del campo.
- Construir al menos una tabla de KPIs ejecutivos que consolide las métricas más relevantes del sector en un formato apto para visualización directa

Consideraciones técnicas transversales a las tres capas

- Idempotencia: el pipeline completo debe poder ejecutarse múltiples veces sobre los mismos datos sin generar duplicados ni alterar el resultado final.
- Manejo de errores: cualquier excepción durante el procesamiento debe ser capturada, registrada en una tabla de errores del pipeline y notificada sin interrumpir la ejecución de las tareas independientes.
- Pruebas de calidad de datos: implementar al menos cinco verificaciones automatizadas utilizando Great Expectations, pruebas de dbt o validaciones personalizadas

ENTREGABLES DE FASE 3

- Código completo de las tres capas del pipeline en la carpeta /pipelines del repositorio
- Tabla de errores del pipeline con al menos un registro de prueba que demuestre su funcionamiento
- Reporte de calidad de datos generado por la capa Silver con métricas de al menos una ejecución
- Al menos tres tablas o vistas de agregación en la capa Gold con sus definiciones documentadas
- Resultados de las cinco pruebas de calidad de datos con el reporte de aprobación o fallo

ENTREGABLE FASE 4 — ORQUESTACION DEL PIPELINE

Todos los pasos del pipeline deben estar orquestados mediante una herramienta formal de gestión de flujos de trabajo. La herramienta elegida debe ser coherente con la plataforma cloud seleccionada y debe permitir la ejecución programada, el monitoreo del estado de cada tarea y la gestión de dependencias.

Opciones de orquestación por Plataforma

Plataforma	Herramientas de orquestacion validas
Microsoft Azure	Azure Data Factory Pipelines, Databricks Workflows, Apache Airflow en Azure Kubernetes Service
Amazon AWS	Amazon Managed Workflows for Apache Airflow (MWAA), AWS Step Functions, AWS Glue Workflows
Google Cloud	Cloud Composer basado en Apache Airflow, Cloud Workflows, Cloud Scheduler combinado con Cloud Run
Microsoft Fabric	Fabric Pipelines, Spark Notebooks con programación integrada

Requisitos del orquestador

- Definir un DAG o pipeline principal con dependencias explícitas entre tareas: la capa Silver solo debe iniciarse cuando Bronze haya completado exitosamente, y Gold solo debe iniciarse cuando Silver haya completado exitosamente.

- Configurar una ejecución programada automática diaria a las 02:00 horas del huso horario local del proyecto.
- Implementar reintentos automáticos con al menos tres intentos por tarea fallida y un intervalo de espera de tipo backoff exponencial entre reintentos.
- Definir un tiempo máximo de ejecución por tarea coherente con el volumen de datos procesado.
- Configurar una alerta de correo electrónico o mensaje en canal de comunicación cuando cualquier tarea del pipeline falle, incluyendo el nombre del DAG, la tarea específica, la fecha y hora de fallo y el mensaje de error.
- Configurar un reporte de resumen diario automático al completarse el pipeline con éxito, que incluya el número de registros procesados por cada capa, el tiempo total de ejecución y el número de alertas de calidad de datos generadas.
- El estado de cada ejecución del pipeline debe ser visible en un dashboard o log de monitoreo accesible sin necesidad de acceder al código fuente.

Flujo de ejecución esperado



ENTREGABLES FASE 4

- Definición del DAG o pipeline principal en la carpeta /orchestration del repositorio
- Captura de pantalla del DAG ejecutado exitosamente con el estado de cada tarea visible

- Evidencia de la alerta de fallo: captura del correo o mensaje recibido ante una ejecución fallida de prueba
- Evidencia del reporte diario de éxito: captura del correo o mensaje de resumen recibido
- Acceso al dashboard o log de monitoreo con el historial de al menos dos ejecuciones

ENTREGABLE FASE 5 — GOBIERNO, SEGURIDAD Y CALIDAD

Un pipeline de datos en producción requiere una capa de gobierno que garantice la seguridad de los accesos, la trazabilidad de los datos y la visibilidad operacional del sistema. Esta fase evalúa la madurez del candidato en la aplicación de buenas prácticas de gobierno de datos y seguridad en la nube.

Gestión de roles y accesos

- Definir e implementar al menos tres roles diferenciados: Ingeniero de Datos con permisos de lectura y escritura en todas las capas, Analista con acceso de solo lectura a la capa Gold, y Administrador con control total sobre los recursos del proyecto.
- Aplicar el principio de mínimo privilegio: cada componente del pipeline debe ejecutarse bajo su propia identidad de servicio o cuenta de servicio, con los permisos estrictamente necesarios para su función.
- Ninguna credencial, clave de acceso o contraseña debe aparecer en el código fuente, archivos de configuración o variables de entorno no cifradas. Todos los secretos deben estar almacenados en el gestor de secretos de la plataforma.
- Habilitar los registros de auditoría de accesos a los datos: el sistema debe ser capaz de responder quien accedió a que dato y en qué momento.

Privacidad y protección de datos sensibles

- Identificar y etiquetar todas las columnas que contengan información de identificación personal en las tablas de origen.
- Aplicar enmascaramiento dinámico o función hash sobre las columnas sensibles a partir de la capa Silver. Los datos originales no deben ser accesibles para el perfil de Analista.

- Mantener un catálogo de datos básico que liste cada tabla de las capas Silver y Gold con la descripción de cada campo, su tipo, su origen y si contiene información sensible

Notificaciones y monitoreo operacional

- Alerta de fallo del pipeline: enviar notificación inmediata cuando cualquier tarea falle, con el nombre de la tarea, la capa afectada, la hora del fallo y el mensaje de error completo.
- Reporte diario de ejecución: enviar un resumen automático al completarse cada ciclo del pipeline con el número de registros procesados por capa, el tiempo de ejecución, y el número de registros rechazados por calidad.
- Alerta de anomalía de volumen: si el número de registros procesados en una ejecución difiere más de un treinta por ciento respecto al promedio de las últimas siete ejecuciones, enviar una alerta diferenciada antes de continuar el pipeline

Linaje y documentación de datos

- Documentar el linaje de datos de al menos tres campos calculados en la capa Gold: tabla de origen, transformaciones aplicadas en orden, y propósito del campo en el contexto del negocio.
- Mantener un CHANGELOG.md en el repositorio que registre cada cambio significativo en el pipeline con la fecha, el autor y la descripción del cambio.

ENTREGABLES FASE 5

- Definición de los tres roles implementados con evidencia de la configuración en la plataforma
- Demostración del acceso denegado: evidencia de que el perfil Analista no puede acceder a las capas Bronze o Silver directamente
- Catálogo de datos básico en formato Markdown ubicado en la carpeta /docs del repositorio
- Evidencia del funcionamiento de las tres alertas: fallo, reporte diario y anomalías de volumen
- CHANGELOG.md con el historial de cambios del proyecto durante el desarrollo de la prueba

RECOMENDACIONES TÉCNICAS Y PROCESO DE ENTREGA

Elementos que elevan la calidad de la solución

- Delta Lake o Apache Iceberg: utilizar formato de tabla ACID sobre Parquet plano para las capas Silver y Gold aporta capacidades de versionado, upserts y viajes en el tiempo.
- dbt (Data Build Tool): utilizar dbt para las transformaciones de Silver y Gold permite generar documentación automática, pruebas declarativas y linaje de datos con mínimo esfuerzo adicional.
- Great Expectations o Soda Core: implementar expectativas de calidad de datos como código, versionadas en el repositorio y ejecutadas como parte del pipeline.
- OpenLineage o Apache Atlas: instrumentar el linaje de datos de forma automática y centralizada en lugar de documentarlo manualmente.
- CI/CD del pipeline: configurar GitHub Actions o Azure DevOps para validar el código, ejecutar las pruebas y desplegar los cambios de forma automática ante cada confirmación en la rama principal.

Errores frecuentes que se penalizan en la evaluación

- Credenciales, tokens o contraseñas presentes en el código fuente o en el historial de commits del repositorio.
- Estado de Terraform confirmado en el repositorio. El archivo terraform.tfstate nunca debe aparecer en el historial de Git.
- Pipeline sin idempotencia: ejecutar el pipeline dos veces sobre los mismos datos no debe producir registros duplicados.
- README sin instrucciones reproducibles: el evaluador debe poder desplegar y ejecutar la solución sin necesidad de hacer preguntas adicionales.
- Decisiones técnicas sin justificación: elegir una herramienta o patrón de diseño sin explicar el razonamiento se considera una brecha en el perfil.

Estructura de carpetas recomendada para el repositorio

Carpeta o archivo	Contenido esperado
/infra	Código IaC completo con README de instrucciones de despliegue
/data-generation	Scripts de generación de datos dummy y archivo de configuración
/pipelines	Código de transformaciones para las tres capas del pipeline
/orchestration	Definición del DAG o pipeline del orquestador elegido
/docs	Diagrama de arquitectura, catálogo de datos y diagrama ER
README.md	Descripción completa de la solución, justificaciones y guía de despliegue e imágenes
CHANGELOG.md	Historial de cambios con fecha, autor y descripción por entrada

Proceso de entrega

1. Crear un repositorio Git en GitHub, GitLab o Bitbucket y compartirlo con el evaluador antes de la fecha límite
2. Incluir en el README como primera sección el sector elegido, la plataforma cloud seleccionada y la justificación de ambas decisiones

Muchas gracias por tu interés y participación.

Esperamos ver tu criterio técnico, tu capacidad de diseño y tu atención al detalle en esta prueba.